

Yazılım Geliştirme Dersi — 2. Proje

**From Black-Box to Explainability:
Probabilistic Automata for Time Series Analysis**

Grup 48

Faruk Öztürk & Nilay Süzer

Teslim: 7 Haziran 2026, 23:59

GitHub: <https://github.com/frkoztrk01/yazlab2>

I. Giriş

Zaman serisi verileri finans, biyomedikal, IoT ve siber güvenlik gibi alanlarda yaygın kullanılmaktadır. Bu projede anomali tespiti, iki modelleme paradigması üzerinden karşılaştırılmıştır: (1) black-box derin öğrenme modelleri (LSTM, GRU, 1D-CNN) ve (2) sembolik temsil ve durum geçiş olasılıklarına dayalı olasılıksal otomata modeli (PAA → SAX → sliding window).

Deneyler SKAB (valve1/valve2) ve BATADAL (Training Dataset 2, ATT_FLAG hedef değişkeni) veri setleri üzerinde yürütülmüştür. Üç senaryo test edilmiştir: orijinal veri, Gaussian gürültü eklenmiş veri ve unseen pattern senaryosu. Her koşul 5 farklı random seed ile tekrarlanmış; sonuçlar ortalama $\pm$ standart sapma olarak raporlanmıştır.

Araştırma sorusu: Farklı modelleme yaklaşımları, farklı veri koşulları altında nasıl davranmaktadır? Proje yalnızca en iyi modeli seçmekten ziyade; performans, genellenebilirlik, gürültüye dayanıklılık, açıklanabilirlik ve hesaplama maliyeti kriterlerini sistematik biçimde karşılaştırmayı hedefler.

II. Deney Sonuçları Tabloları

Aşağıdaki beş tablo, EK doküman formatında deney sonuçlarını özetler. Tablolar sırasıyla model performansı, gürültü/unseen dayanıklılığı, cross-dataset transfer, otomata parametre duyarlılığı ve çalışma süresi karşılaştırmalarını içermektedir.

Tablo 1: Model Performansı ve Stabilitesi (Ortalama F1-score $\pm$ Standart Sapma)

Her modelin SKAB ve BATADAL veri setlerindeki ortalama F1 skorunu ve 5 tekrarlı deneydeki standart sapmasını gösterir; model stabilitesini karşılaştırır.

Model	SKAB	BATADAL
LSTM	0.843 $\pm$ 0.008	0.268 $\pm$ 0.036
GRU	0.837 $\pm$ 0.013	0.226 $\pm$ 0.040
1D-CNN	0.832 $\pm$ 0.013	0.294 $\pm$ 0.073
Automata	0.368 $\pm$ 0.035	0.000 $\pm$ 0.000

Tablo 2: Gürültü Etkisi ve Unseen Senaryo Analizi

SKAB üzerinde orijinal ve gürültülü senaryolardaki F1 değerlerini raporlar. Otomata için unseen pattern senaryosunda detection rate ve mapping accuracy sunulur.

Model	Orijinal (F1)	Gürültülü (F1)	Det. Rate	Map. Acc.
LSTM	0.843 $\pm$ 0.008	0.833 $\pm$ 0.013	—	—
GRU	0.837 $\pm$ 0.013	0.827 $\pm$ 0.009	—	—
1D-CNN	0.832 $\pm$ 0.013	0.830 $\pm$ 0.013	—	—
Automata	0.368 $\pm$ 0.035	0.370 $\pm$ 0.047	1.000	1.000

Tablo 3: Cross-Dataset Performans Karşılaştırması (F1-score)

Bir veri setinde eğitilen LSTM modelinin diğer veri setinde test edildiğinde elde ettiği F1 skorlarını gösterir; veri setleri arası genellenebilirliği ölçer.

Train / Test	SKAB	BATADAL
Train: SKAB	0.238	0.083
Train: BATADAL	0.519	0.099

Tablo 4: Automata Parametre Duyarlılık Analizi (F1-score, SKAB)

Otomata modelinde window size ve alphabet size parametrelerinin SKAB performansına etkisini analiz eder; sabit karşılaştırma değerleri window=4, alphabet=3'tür.

Parametre	Değer = 3	Değer = 4	Değer = 5	Değer = 6
Window Size	0.459	0.368	0.433	0.424
Alphabet Size	0.368	0.488	0.512	0.526

Tablo 5: Modellerin Çalışma Süresi (Runtime) Karşılaştırması

Modellerin ortalama eğitim ve çıkarım sürelerini (saniye) karşılaştırır; hesaplama maliyeti açısından DL ile otomata arasındaki farkı gösterir.

Model	Training Time (sn)	Inference Time (sn)
LSTM	5.067	0.035
GRU	3.980	0.019
1D-CNN	3.212	0.032
Automata	0.002	0.000